گزارش فنی و بستهٔ کد راهکارهای سه چالش Sakko

مخاطب: برگزارکننده و هیئت داوری نهمین هکتون علم داده و هوش مصنوعی ICDS
تاریخ تهیه: ۲۷ سپتامبر ۲۰۲۶
پیوست‌ها: کد منبع، خروجی‌های مرجع، کنترل هش و ابزار بازسازی cached

اعلام استفاده از ابزارهای هوش مصنوعی: در بخش‌هایی از پژوهش، کدنویسی، تحلیل آزمایش‌ها و تدوین مستندات از دستیارهای مبتنی بر LLM استفاده شده است. امتیازهای گزارش‌شده حاصل ارزیابی فایل‌های CSV در سامانهٔ مسابقه‌اند، نه خروجی مستقیم یک LLM.

۱. دامنهٔ تحویل و نتایج

این گزارش، مسئله، داده، روش مدل‌سازی، آموزش، ارزیابی و بازتولید راهکارهای سه سؤال را شرح می‌دهد. هر نتیجهٔ عمومی به **نام و هش فایل خروجی مشخص** متصل شده است. ما به برچسب‌های مجموعهٔ آزمون یا ارزیابی private دسترسی نداریم؛ در نتیجه امتیازهای زیر همان اعداد ثبت‌شدهٔ سامانهٔ عمومی‌اند و مستقلاً از برچسب‌های پنهان محاسبه نشده‌اند.

سؤال	خروجی مرجع	امتیاز عمومی ثبت‌شده	وضعیت روش
۱، دودویی	`submission_model_v42_0.837.csv`	Balanced Accuracy **۰٫۸۳۷**	مدل‌های آموزش‌دیده با هدف دودویی سؤال ۱؛ بازسازی دقیق از احتمال‌های مدلِ همراه بسته کنترل شد.
۱، نتیجهٔ مسابقه‌ای	`submission_competition_v80_0.844.csv`	Balanced Accuracy **۰٫۸۴۴**	ترکیب خروجی سؤال ۱ با سیگنال سؤال ۲ و انتخاب مبتنی بر نتایج عمومی؛ از مسیر مستقلِ فقط سؤال ۱ جداست.
۲، چهارکلاسه	`submission_challenge2_v120_prior_P.csv`	Balanced Accuracy **۰٫۶۷۴**	مدل‌های پایه با هدف سؤال ۲؛ تصمیم نهایی از posterior فریزشدهٔ برازش‌یافته با بازخورد عمومی دقیقاً بازسازی می‌شود.
۳، رگرسیون	`submission_challenge3_v114_yb300_nov08.csv`	**۴۲٫۰۹۴**؛ کمتر بهتر	مدل توزیعی مدت با سیگنال‌های سؤال‌های ۱ و ۲، اصلاح زمانی و تصمیم متناسب با معیار.

۲. تعریف مسئله و داده

هر نمونه یک آیتم از اعلان کیفیت است. کلید اتصال و کنترل یکتایی، جفت `(Notification, Item)` است. دادهٔ آموزش ۷۳,۲۳۹ آیتم در ۱۹,۷۰۱ اعلان و دادهٔ آزمون ۸,۳۲۳ آیتم در ۲,۲۵۲ اعلان دارد. بازهٔ ایجاد train از ۲۶ نوامبر ۲۰۰۷ تا ۳۰ دسامبر ۲۰۲۴ و بازهٔ test از ۳۱ دسامبر ۲۰۲۴ تا ۳۱ دسامبر ۲۰۲۵ است. ترتیب `items_test.csv` در هر سه CSV خروجی حفظ شده است.

سه فایل هدف train عبارت‌اند از `target_binary_train.csv` با ستون `rework_length`، `target_multiclass_train.csv` با ستون `rework_bin` و `target_regression_train.csv` با ستون واقعی `Actual Work Minute`. خروجی‌ها به‌ترتیب فقط ستون‌های `pred_rework_length`، `pred_rework_bin` و `pred_rework_minutes` دارند. در سؤال ۱، `long` به زمان بیش از ۴۸۰ دقیقه اشاره دارد. چهار کلاس سؤال ۲، `quick_le_2h`، `same_day_2_8h`، `multi_shift_8_24h` و `multi_day_gt_24h` هستند. در سؤال ۳، مقدار حقیقی و پیش‌بینی هنگام ارزیابی به بازهٔ ۱۲۰ تا ۲۰۰۰ دقیقه محدود می‌شوند.

برای سؤال‌های ۱ و ۲، Balanced Accuracy میانگین recall کلاس‌هاست: `BA = (1/K) * sum_c TP_c / N_c` که در آن `K` به‌ترتیب ۲ یا ۴ و `N_c` شمار واقعی کلاس `c` است. برای سؤال ۳، تعریف دقیق معیار در بخش ۶ آمده است. بدون برچسب‌های پنهان آزمون، این معیارها برای فایل‌های test در سمت ما محاسبه‌شدنی نیستند.

ویژگی‌های ورودی از جدول آیتم، نخستین فعالیت واجد شرایط در کمتر از ۲۴ ساعت، اطلاعات پایهٔ قطعه/مجموعه، درخت ساخت MAS و embeddingهای ۴۰۹۶بعدی شرح آیتم، فعالیت و ماده به دست می‌آیند. فایل کلید هر embedding با ماتریس همان خانواده، سطر به سطر هم‌تراز می‌شود. `mas_trees` پیش از اتصال به آیتم در سطح `tree_id` تجمیع می‌شود. دادهٔ اختیاری با اتصال چپ افزوده می‌شود تا آیتمی حذف نشود. صفر ثبت‌شده با مقدار مفقود یکسان فرض نمی‌شود.

۳. آماده‌سازی، تقسیم زمانی و کنترل نشت

برای هر سؤال، برچسب‌های train فقط بر اساس کلید مرکب به آیتم‌ها وصل می‌شوند. شناسه‌های `Notification` و `Item` به فایل ارسال نهایی افزوده نمی‌شوند. ویژگی‌های شمارشیِ دم‌سنگین با تبدیل‌های مقاوم مانند `log1p` و پرچم‌های فقدان متن/فعالیت همراه می‌شوند. کاهش بُعد متن با PCA در بخش آموزشِ هر ارزیابی برازش می‌شود؛ مرتب‌سازی مستقل فایل keys و embedding مجاز نیست.

اعتبارسنجی به‌ترتیب زمان ایجاد آیتم انجام شده است. مدل‌هایی که نیمهٔ دوم ۲۰۲۴ را ارزیابی می‌کنند، روی دورهٔ پیش از آن آموزش می‌بینند. ویژگی‌های تاریخچهٔ هدف فقط از رکوردهای قدیمی‌تر استفاده می‌کنند؛ همسایه‌های متنیِ برچسب‌دار از همان `Notification` حذف می‌شوند. برای پیش‌بینی آزمون ۲۰۲۵، مدل از دادهٔ برچسب‌دار تا پایان ۲۰۲۴ استفاده می‌کند. برخی جدول‌های بدون برچسب، اسنپ‌شات عرضه‌شدهٔ مسابقه‌اند؛ بنابراین اعتبارسنجی محلی معادل بازسازی کامل وضعیت سامانه در زمان واقعی نیست. دوره‌های Q3/Q4-2024 در جریان پژوهش چندبار دیده شده‌اند و شاهد آزمون مستقل محسوب نمی‌شوند.

الگوی مهم در آزمون، ۶۵۴ آیتمِ ایجادشده از ۶ دسامبر ۲۰۲۵ به بعد و فاقد بردار شرح آیتم است. نسخه‌های منتخب در این زیرگروه به‌ترتیب برچسب `short`، برچسب `quick_le_2h` و مقدار ۱۲۰ دقیقه می‌دهند. افت هم‌زمان پوشش متن و فعالیت، فرض اسنپ‌شاتِ بریده‌شده و ثبت‌نشدن کامل کار را مطرح کرد و ارزیابی عمومی نیز این قاعده را پشتیبانی کرد. **این فرضیه دربارهٔ فرایند داده است، نه مشاهدهٔ برچسب واقعی آن ۶۵۴ ردیف**؛ علت قطعی جمع‌آوری داده و حقیقت هر ردیف برای ما معلوم نیست.

۴. روش و نتیجهٔ سؤال ۱

مدل‌های اصلی v42، چند CatBoost جدولی با seedهای متفاوت و شاخه‌های مکمل هستند. پیکربندی پایه حدود ۹۰۰ درخت، عمق ۸، نرخ یادگیری ۰٫۰۴۵ و L2 برابر ۸ دارد. وزن نمونه‌ها با نیمه‌عمر زمانی دو سال کاهش می‌یابد و کلاس‌های دودویی در آموزش متوازن می‌شوند. ده جزء شامل سه seed پایه، CatBoost عمیق‌تر، زمینهٔ اعلان، تاریخچهٔ اعلان، نگاشت Severity، ویژگی بار عیب، سیگنال long و فشرده‌سازی نظارت‌شدهٔ متن‌اند. ویژگی‌های تاریخیِ اعلان، ماده، درخت و کد عیب تنها از رکوردهای قدیمی‌تر ساخته می‌شوند.

در v42، ابتدا میانگین logit ده احتمال محاسبه، روی آیتم‌های پیش از cutoff استاندارد و در ۲٫۶۱۴ ضرب می‌شود. سپس جریمهٔ نزدیک‌شدن به ۶ دسامبر ۲۰۲۵ برابر `3.0 * exp(-d/15)` کم می‌شود که `d` تعداد روزهای باقیمانده تا cutoff است؛ قبل از logit هر احتمال در `[1e-6,1-1e-6]` محدود می‌شود. ۶۵۴ ردیفِ متأخرِ بدون متن از انتخاب long کنار گذاشته می‌شوند و ۳٬۷۰۰ ردیف با امتیاز بالاتر long می‌شوند. این تعداد، پارامتر تصمیم منتخب است و به معنی دسترسی به سهم واقعی کلاس‌های تست نیست. فایل v42 از بردارهای احتمال همراه کد دقیقاً بازسازی شد؛ SHA-256 تولیدشده با مرجع برابر بود.

مسیر ثبت‌شدهٔ پیشرفت سؤال ۱، با تفکیک تغییر روش از تغییر امتیاز، چنین است:

نسخه	امتیاز عمومی BA	تغییر اصلی
v1	۰٫۸۲۰	مبنای مدل‌های اولیه
v32	۰٫۸۳۳	تشخیص برش داده در ۶ دسامبر و قاعدهٔ گروه بدون متن
v42	۰٫۸۳۷	جریمهٔ پیوستهٔ نزدیکی به برش روی امتیاز مدل
v62	۰٫۸۳۸	تنظیم تصمیم با بازخورد لیدربورد عمومی
v71 تا v72	۰٫۸۴۱ تا ۰٫۸۴۲	افزودن سیگنال مدل سؤال ۲ و تنظیم شمار long
v75	۰٫۸۴۳	انتخاب ترکیب و تصمیم روی ردیف‌های نامطمئن
v80	**۰٫۸۴۴**	گزینش Monte Carlo روی ردیف‌های محل اختلاف؛ ۳٬۷۳۰ برچسب long

سیگنال مکمل سؤال ۲ از جمع احتمال‌های `multi_shift_8_24h` و `multi_day_gt_24h` ساخته شد. در یک اعتبارسنجی محلی هم‌برش برای زیرسامانهٔ دوم، AUC این سیگنال حدود ۰٫۹۰۲۸ و AUC ترکیب پایهٔ سؤال ۱ حدود ۰٫۸۹۱۵ گزارش شد؛ این اعداد معادل امتیاز رسمی یا آزمون مستقل نیستند. مرحلهٔ آخر روی ۵۲۸ ردیفِ دارای اختلاف میان نامزدها شبیه‌سازی و با امتیازهای عمومی قبلی کالیبره شد. آزمایش‌های عمق ۱۲ به‌تنهایی، seedهای بیشتر و وزن اغراق‌آمیز برای زیرسامانهٔ دوم بهبود پایدار ندادند.

فایل v80 با ۳٬۷۳۰ long، بهترین نتیجهٔ عمومی ثبت‌شدهٔ سؤال ۱ را دارد. انتخاب آن علاوه بر مدل‌های سؤال ۱ از احتمال‌های سؤال ۲ و چندین نتیجهٔ عمومی استفاده کرده است. کد مدل و کد تحلیل مسابقه‌ای در پیوست موجودند، اما یک اجرای مستقل از دادهٔ خام که بیت‌به‌بیت v80 را بسازد در این بسته اثبات نشده است. بنابراین v42 مسیر اصلیِ قابل‌بازتولید برای بررسی روشِ فقط دودویی است و v80 سند نتیجهٔ مسابقه‌ای با منشأ متفاوت.

۵. روش و نتیجهٔ سؤال ۲

چهار احتمال کلاس از مدل‌های CatBoost، مدل‌های one-vs-rest/سلسله‌مراتبی و سیگنال‌های ordinal و تجمعی ساخته می‌شوند. شاخهٔ V7-C2 با CatBoost `MultiClass`، عمق ۸، L2 برابر ۱۰، نرخ یادگیری ۰٫۰۳، نیمه‌عمر زمانی ۰٫۵ سال و وزن بیشتر برای زیرسامانهٔ دوم آموزش دیده است. شناسه‌های خام با تعداد دستهٔ بسیار زیاد در آن حذف می‌شوند. آموزش اعتبارسنجی پیش از ۱ ژوئیهٔ ۲۰۲۴ و بررسی روی نیمهٔ دوم آن سال است؛ سپس مدل نهایی روی همهٔ برچسب‌های مجاز سؤال ۲ برازش می‌شود.

گام مؤثر نخست، تصحیح ۶۵۴ ردیف cutoff بود: نسخهٔ v16 امتیاز ۰٫۶۱۴ و نسخهٔ v40 پس از این قاعده ۰٫۶۴۵ گرفت. با ترکیب logits و تعدیل‌های محدودِ زمانی، v74 به ۰٫۶۶۱ و v92 به ۰٫۶۶۶ رسید. برای نسخهٔ نهایی، posterior ردیفی از خروجی مدل‌های پایه، سهم‌های منتشرشدهٔ چهار کلاس `[1804, 3876, 1619, 1024]` و امتیازهای عمومی قبلی برآورد شد. تصمیم هر ردیف، کلاس با بیشترین `q[i,c]/N[c]` است و ردیف‌های cutoff quick می‌مانند؛ این با هدف Balanced Accuracy سازگار است.

نسخه	امتیاز عمومی BA	تغییر اصلی
v16 → v40	۰٫۶۱۴ → ۰٫۶۴۵	اصلاح گروه پس از برش ۶ دسامبر
v54 → v74	۰٫۶۶۱ → ۰٫۶۵۱	تنظیم زمانی، ترکیب مدل‌ها و تقویت شاخهٔ زیرسامانهٔ دوم
v89 → v92	۰٫۶۶۶ → ۰٫۶۶۵	اصلاح محدود تصمیم‌های زمانی
v99 → v105	۰٫۶۷۲ → ۰٫۶۷۱	posterior ردیفی از قیود امتیاز عمومی
v120	**۰٫۶۷۴**	انتخاب نهایی از posterior فریزشده

تقریباً ۰٫۰۰۸ از بهترین امتیاز نسبت به نسخه‌های پیش از برازش posterior، از بازخورد عمومی و قیود ردیفی آن آمده است؛ انتقال این بخش به ارزیابی private معلوم نیست. تحلیل داده همچنین نشان داد ثبت کار در هفته‌های آخر اسنپ‌شات ناقص است و توزیع کلاس‌ها در طول زمان جابه‌جا می‌شود. شاخهٔ V7-C2، هرچند از ایدهٔ معماری سؤال ۳ الهام گرفت، با **برچسب‌های خود سؤال ۲** آموزش داده شد. نسخهٔ v123 در گزارش پژوهشی آمده اما امتیاز رسمی آن هنگام تهیهٔ این سند ثبت نشده است.

صورت فنیِ برازش posterior در `lbpost.py` چنین است. برای هر ارسال قبلی `s`، با شمار کلاس منتشرشدهٔ `N_c`، مقدار مورد انتظار `BA(s)` از احتمال ردیفی `q[i,c]` حساب می‌شود. از prior مدل `p[i,c]` شروع می‌کنیم و مجموع `KL(q||p)`، اختلاف مربعی با امتیازهای عمومی و اختلاف مربعی با شمار کلاس‌های منتشرشده را کمینه می‌کنیم. پارامترهای tilt با `torch.optim.LBFGS` برازش می‌شوند. گزارش پژوهشی برای leave-one-out روی امتیازهای قبلی RMSE حدود ۰٫۰۰۱۳ ثبت کرده است؛ این آزمونِ پیش‌بینی **امتیاز لیدربورد** است، نه اعتبارسنجی برچسب مستقل. `crossprior.py` سه prior با نام P/A/C را به آرایهٔ `(3,8323,4)` در `Q_PAC.npy` تبدیل می‌کند؛ v120 فقط prior شمارهٔ P را می‌خواند.

فایل منتخب v120 امتیاز عمومی **۰٫۶۷۴** دارد. اسکریپت پیوست `reproduce_c2_v120_cached.py` از آرایهٔ فریزشدهٔ `Q_PAC.npy`، دادهٔ کلید متن و `items_test.csv`، فایل v120 را با همان SHA-256 بازسازی کرد. `Q_PAC.npy` در `crossprior.py` از مدل posterior و نتایج عمومی ساخته شده است. بازسازی cached، آموزش دوبارهٔ تمام مدل‌های پایه یا تولید مستقل posterior از دادهٔ خام نیست؛ کدهای آموزش و آزمایش در پیوست منبع آمده‌اند.

۶. روش و نتیجهٔ سؤال ۳

هدف، پیش‌بینی دقیقهٔ کار با معیار زیر است؛ پیش از محاسبه، هر دو بردار حقیقت و پیش‌بینی در `[120,2000]` clip می‌شوند:

```
score = 50 * (mean(abs(p-y)/y) + sum(abs(p-y))/sum(y))
```

به‌جای میانگین مستقیم زمان، CatBoost توزیع مدت در بازه‌های ریز را تخمین می‌زند. شاخه‌های تاریخچهٔ fine، مدل بدون تاریخچه و مدل lean با تنظیم وزن زمانی ترکیب می‌شوند. شاخهٔ lean، بعضی target encodingها و شناسه‌های خام را کنار می‌گذارد و با CatBoost `MultiClass`، عمق ۶، L2 برابر ۱۵ و نرخ ۰٫۰۵ آموزش می‌بیند. احتمالات چهار گروه زمانی از مدل سؤال ۲ و احتمال دودویی از سؤال ۱ به توزیع ریز منتقل می‌شوند؛ دمای کلاس‌ها و سهم هر منبع در اعتبارسنجی و سپس در آزمایش‌های عمومی تنظیم شده است.

برای تبدیل توزیع به عدد، کد `reg_model.py` در شبکهٔ ۵دقیقه‌ای، پیش‌بینی با کمترین امید زیان `abs(p-y)*(1/y+1/ybar)` را انتخاب می‌کند. جدول زیان از برچسب‌های train در هر بازهٔ ریز و وزن زمانی ساخته می‌شود. در v114، `ybar=300` است. ۶۵۴ ردیف cutoff مقدار ۱۲۰ می‌گیرند؛ برای ردیف‌های پیش از cutoff، سهم کلاس‌های طولانی و quick بر اساس فاصلهٔ زمانی و بازه‌های اکتبر/نوامبر اصلاح می‌شود.

در این تصمیم، `1/y` از جزء خطای نسبی معیار و `1/ybar` تقریب ثابتِ جملهٔ `sum(abs(p-y))/sum(y)` است؛ `ybar=300` با ارزیابی عمومی انتخاب شد و برابر میانگین واقعیِ ناشناختهٔ test فرض نشده است. احتمالات بازه‌های ریز نخست از CatBoost به دست می‌آیند، سپس با احتمال گروه زمانی چهارکلاسه و احتمال دودویی انتقال داده می‌شوند؛ مقدار نهایی یک عدد دقیقه است، نه برچسب بازه.

پارامترهای فراخوانی پیش‌فرض سازندهٔ v114 در `make_v114.py` عبارت‌اند از `k=0.8` برای quick نوامبر، `k_oct=0.6` برای بازهٔ اکتبر، `a=0.8` برای سهم ترکیب گروهی، `gmd=0.08` برای تنظیم multi-day، `dl=-3.0` و `dq=-0.5` برای کاهش پیش از برش، `w=0.25` برای سهم شاخهٔ V7، `gamma=0.6` در انتقال احتمال دودویی، و دماهای نسبی `(1.6, 1.6, 3.0, 2.2)` برای چهار گروه. نام متغیرهای دقیق و ترتیب اجرای آن‌ها در کد پیوست است؛ این مقادیر با تکرار اعتبارسنجی و امتیازهای عمومی انتخاب شده‌اند، نه با برچسب test.

گزارش نشست، **۴۴٫۴۸۸** را نقطهٔ شروع تیم ثبت می‌کند، ولی فایل CSV متناظر با آن در این تحویل شناسایی نشده و بنابراین در جدول فایل‌های مرجع نیست. مسیر نسخه‌های دارای ثبت امتیاز تا v114 چنین است:

نسخه	امتیاز عمومی؛ کمتر بهتر	تغییر اصلی
v50 → v56	۴۳٫۴۰۸ → ۴۳٫۹۴۳	اصلاح برش، سیگنال کلاس و قاعدهٔ تصمیم
v63 تا v72	۴۳٫۶۶۶	تنظیم احتمالات گروه‌های زمانی
v83	۴۳٫۳۴۷	تقویت اطلاعات سؤال ۲ و اصلاح زیرگروه‌های زمانی
v87 → v96	۴۳٫۲۲۰ → ۴۳٫۱۶۳	تقویت quick در نوامبر و تنظیم پارامترهای تصمیم
v112، v103 و v114	**۴۲٫۰۹۴**	ترکیب نهایی و انتخاب با نتایج عمومی

در تحلیل counterfactual محلی، اگر گروه زمانی واقعی از پیش معلوم بود، معیار از حدود ۴۵٫۹۸ به ۱۵٫۰۸ می‌رسید. این آزمایش نشان می‌دهد سهم بزرگی از خطا به انتخاب گروه زمانی مربوط است؛ چون گروه حقیقیِ تست در دسترس نیست، این عدد نتیجهٔ قابل‌ارسال نیست. بازآموزی مدل پایه به‌تنهایی اثر محدودتری از اصلاح احتمال گروه‌ها داشت. یک نامزد جدید به نام v129 با برآورد Monte Carlo برابر ۴۲٫۰۸۲ و احتمال مدل‌شدهٔ حدود ۷۴٪ برای بهبود انتخاب شده بود، اما **امتیاز رسمی v129 ثبت نشده** و به‌عنوان بهترین نتیجه معرفی نمی‌شود. امتیاز v99 نیز در گزارش نشست نامعلوم است.

v114 با `challenge_3/v93_lean/make_v114.py` از خروجی‌های مدل و کش‌های سه سؤال ساخته می‌شود. اجرای دوبارهٔ زنجیرهٔ کامل از دادهٔ خام در این تحویل انجام نشده است؛ فایل مرجع، کد آموزش/ترکیب و هش خروجی برای بررسی ارائه شده‌اند. به‌سبب استفاده از سیگنال سؤال‌های ۱ و ۲، داور باید انطباق این مسیر با شرط فایل هدف همان سؤال را ارزیابی کند.

۷. وابستگی‌ها، ساختار کد و اجرای دوباره

محیط اصلی Windows/PowerShell و Python 3.12 با GPU انویدیا بوده است. برای مسیر بسته‌بندی‌شدهٔ سؤال ۱، فایل `challenge_1/submission_package_c1/requirements.txt` شامل scikit-learn 1.6.1، CatBoost 1.2.8، PyArrow 19.0.1، NumPy 2.1.3، Pandas 2.3.0، SciPy 1.16.0 و PyTorch 2.6.0 است. فایل `challenge_2/requirements_multiclass.txt` برای مسیر سؤال ۲ **NumPy 2.3.1** را درخواست می‌کند و LightGBM 4.6.0 نیز دارد. بنابراین نصب بی‌قید هر دو فایل requirements در یک محیط، نسخهٔ NumPy را متعارض می‌کند؛ برای آموزش دو مسیر، محیط‌های مجزا بسازید. نسخهٔ CUDA باید با GPU دستگاه مقصد سازگار باشد. بازسازی cached سؤال ۲ فقط به NumPy، Pandas و PyArrow نیاز دارد؛ برای ساخت HTML از Markdown پایتون و برای PDF از مرورگر دارای چاپ PDF استفاده شده است.

پوشهٔ `source/` در ZIP تحویلی، **کدهای Python**، **دفترهای `.ipynb`**، **تنظیمات JSON** و **فایل‌های متنی لازم** را به‌صورت مستقیم و با مسیرهای اصلی پروژه دارد؛ آرشیو تودرتو یا گزارش‌های قدیمی داخل آن نیست. مسیر اصلی سؤال ۱ در `source/challenge_1/submission_package_c1/source/challenge_1/hour_v1`، سؤال ۲ در `source/challenge_2/solution` و `source/challenge_2/v40_cutoff`، و سؤال ۳ در `source/challenge_3/solution`، `source/challenge_3/v50_cutoff` و `source/challenge_3/v93_lean` قرار دارد. بسته ۵۵۰ فایل Python در `source/`، ۱۳ notebook و بردارهای کوچک لازم برای بازسازی cached v42 را دارد. `SHA256SUMS.txt` در ریشهٔ ZIP هش تک‌تک اعضا را مشخص می‌کند. دادهٔ رسمی، مدل‌های `.cbm`، embeddingهای حجیم و cacheهای حجیم C2/C3 در آن قرار نگرفته‌اند. بعضی کدهای پژوهشی مسیر مطلق `D:/project/Sakko` دارند و در محیط مقصد باید مسیرها اصلاح شوند. **«کد کامل» در این تحویل به معنی ارائهٔ کد منبع پژوهش و سازنده‌هاست، نه یک بستهٔ خودبسندهٔ تمام داده‌ها و وزن مدل‌ها.**

از ریشهٔ بستهٔ تحویل، کنترل مرجع و بازسازی cached سؤال ۲ چنین است:

```
python verify_references.py
python reproduce_c2_v120_cached.py --data-dir D:\project\Sakko\data\train_test_features --out
reproduced_v120.csv
```

پس از استخراج ZIP تحویلی، بازسازی v42 با دادهٔ رسمی چنین است:

```
python
source/challenge_1/submission_package_c1/source/challenge_1/hour_v1/reproduce_solution.py --
mode cached --data-dir D:\project\Sakko\data\train_test_features --out reproduced_v42.csv --
verify-reference
```

حالت `--mode train` همان اسکریپت، ده جزء سؤال ۱ را از دادهٔ رسمی آموزش می‌دهد و به GPU نیاز دارد. برای بازآموزی کامل سؤال‌های ۲ و ۳ باید ابتدا ویژگی‌ها و خروجی مدل‌های پایه، سپس اسکریپت‌های ترکیب/تصمیم اجرا شوند. جدول مراحل و فایل‌های ورودی هر کد در خود فایل‌ها و READMEهای همراه قرار دارد؛ اجرای کامل از صفر در این بسته آزموده نشده است. بنابراین داوری می‌تواند قالب و هش همهٔ فایل‌های مرجع، و بازسازی cached دو مسیر یادشده را مستقل کنترل کند؛ برای بررسی آموزش کامل، داده و cacheهای مدل لازم است.

۷.۱. نقشهٔ کد و ترتیب اجرای روش

مرحله	کد اصلی	خروجی/وابستگی
اتصال و ویژگی‌های پایه	`shared_features/build_features.py`، `challenge_1/run_challenge.py`، `challenge_2/solution/train_cb.py`	جدول‌های آیتم، فعالیت، ماده، MAS و embeddingهای کلیددار؛ cacheهای ویژگی
مدل دودویی و اعتبارسنجی زمانی	`challenge_1/hour_v1/pipeline.py`، `evaluate.py`، `neighbors.py`	احتمال‌های ۱۰ جزء v42؛ برچسب فقط از هدف سؤال ۱
ساخت v42	`challenge_1/submission_package_c1/source/challenge_1/hour_v1/reproduce_solution.py`	CSV مرجع ۰٫۸۳۷؛ حالت cached کنترل‌شده
مدل چهارکلاسه	`challenge_2/solution/train_cb.py`، `challenge_2/v40_cutoff/v7c2/train_v7c2.py`	احتمال‌های چهار کلاس؛ شاخهٔ V7-C2 با هدف سؤال ۲
برازش لیدربورد و ساخت v120	`challenge_2/v40_cutoff/lbpost.py`، `crossprior.py`، سپس `reproduce_c2_v120_cached.py`	`Q_PAC.npy` و CSV مرجع ۰٫۶۷۴
مدل توزیعی سؤال ۳	`challenge_3/solution/reg_model.py`، `challenge_3/v93_lean/train_final2.py`	توزیع بازه‌های ریز مدت و جدول زیان
اصلاح برش و ساخت v114	`challenge_3/v50_cutoff/make_v50.py`، `challenge_3/v93_lean/make_v114.py`	به cacheهای هر سه سؤال وابسته؛ CSV مرجع ۴۲٫۰۹۴
انتخاب مسابقه‌ای v80	`challenge_1/hour_v1/lb_prior_r3.py`، `lb_mcmc_pick.py` و سازنده‌های مرتبط	به بردارهای C1/C2 و دفتر امتیازهای عمومی وابسته

۷.۲. سطح بازتولید هر خروجی

خروجی	آنچه با همین تحویل کنترل شده	آنچه با همین تحویل اثبات نشده
C1 v42	تولید مجدد CSV از ۱۰ بردار احتمال، تاریخ/کلید دادهٔ رسمی و کد؛ هش بایت‌به‌بایت برابر	تکرار کل آموزش GPU روی دستگاه مستقل و همان هش
C1 v80	فایل مرجع، قالب، تعداد ردیف و هش	تولید یک‌مرحله‌ای از دادهٔ خام؛ cacheهای C2 و همهٔ آزمایش‌های انتخاب همراه بسته نیستند
C2 v120	تولید مجدد CSV از `Q_PAC.npy` و کلیدهای test؛ هش بایت‌به‌بایت برابر	بازسازی `Q_PAC.npy` از دادهٔ خام و تمام ارسال‌های گذشته
C3 v114	فایل مرجع، قالب، بازهٔ پیش‌بینی و هش؛ کد ترکیب/مدل موجود	اجرای مستقل سازنده از دادهٔ خام بدون cacheهای C1/C2/C3 و رفع مسیرهای مطلق

برای ساخت کامل سؤال ۲ از ابتدا، باید ابتدا cache ویژگی `challenge_2/solution/cache` با دادهٔ رسمی فراهم شود، سپس `train_v7c2.py 3` و سایر شاخه‌های مدل اجرا شوند، فایل‌های احتمال و تمام CSV/امتیازهای قبلی به `lbpost.py` و `crossprior.py` داده شوند و سرانجام تصمیم v120 ساخته شود. برای سؤال ۳، `make_v50.py` دست‌کم سه آرایهٔ احتمال رگرسیون و خروجی‌های ordinal و دودویی سؤال‌های دیگر را از cache می‌خواند؛ `make_v114.py` علاوه بر آن `Ptest_V7.npy` و ماژول‌های میانی را وارد می‌کند. بنابراین این دو مسیر در ZIP حاضر **کد و روش** دارند، اما فرمان مستقل و آزموده‌شدهٔ «دادهٔ خام تا CSV نهایی» ندارند. این محدودیت به داور اجازه می‌دهد بین بازتولید کد، بازپخش cache و صرفِ کنترل خروجی فرق بگذارد.

۸. کنترل خروجی‌ها و منشأ امتیاز

خروجی	تعداد	ستون	SHA-256
C1 v42	۸,۳۲۳	`pred_rework_length`	`c528d2be0927f3b6950b5205495592ea8d2c9f8d9ca2ce6d031c46efd68c9020`
C1 v80	۸,۳۲۳	`pred_rework_length`	`45b1015cb46ba06a0f4dd8dccf2ea76ab377160ba009a6907af3320f340cd42c`
C2 v120	۸,۳۲۳	`pred_rework_bin`	`de0d63c0cffde9175d2e08078238a1ce03ed10e21067c533b15dc7fedc9689a8`
C3 v114	۸,۳۲۳	`pred_rework_minutes`	`dec35954fbb474d0767bd00e71440d770a6096d561e8f8d1164624518e169cc8`

کنترل‌گر پیوست، ستون، تعداد، دامنهٔ مقدار و هش هر فایل را بررسی می‌کند. بازسازی cached v42 و v120 در محیط اصلی اجرا شد و هر دو دقیقاً با هش مرجع برابر بودند. امتیازهای عمومی C1 در دفتر `challenge_1/hour_v1/artifacts/leaderboard_scores.json`، C2 v120 در `challenge_2/v40_cutoff/final_shot.py` و C3 v114 در جدول مشاهدات کد `challenge_3/v93_lean/mc_pick2c.py` ثبت شده‌اند. این سوابق جای تأیید مستقلِ برگزارکننده یا آزمون private را نمی‌گیرند.

ملاک خروجی تحویلی، چهار CSV مرجع و هش‌های همین گزارش است. کدهای پژوهشی برای ممیزی فنی در `source/` قرار دارند.

۹. موارد ناموفق، عدم‌قطعیت‌ها و تصمیم مورد نیاز داور

موضوع	مشاهدهٔ ثبت‌شده	نتیجهٔ قابل‌دفاع
C1: عمق ۱۲، seedهای بیشتر یا وزن بسیار زیاد زیرسامانهٔ دوم	هیچ‌کدام به‌تنهایی بهتر از مسیر منتخب نشدند؛ مدل بدون تصحیح برش هم افت کرد	عامل اصلی جهش اولیه، شناخت ساختار زمانی داده بود.
C2: اصلاح سراسری quick یا کاهش کلاس‌های بلندِ اواخر سال	چند آزمایش عمومی زیان داد؛ اصلاح زمان‌مند محدود بهتر بود	تغییرات محلیِ سازگار با تاریخ، برتر از جابه‌جایی یکسان همهٔ ردیف‌ها بود.
C3: اتکای تنها به Q4-2024 یا بازآموزی پایه	مدل‌های کمکی قابل cutoff به‌علت تفاوت Q4 قیاس نبود؛ تغییرات پایه اثر کوچک داشت	بررسی گروه زمانی و سیگنال‌های مکمل اهمیت بیشتری داشت.
قاعدهٔ ۶ دسامبر	با فقدان ناگهانی متن/فعالیت و نتایج عمومی سازگار است	تاریخ برداشت داده و برچسب واقعی تک‌تک ردیف‌ها تأیید مستقل نشده‌اند.

موضوع	مشاهدهٔ ثبت‌شده	نتیجهٔ قابل‌دفاع
posterior لیدربورد	در C2 حدود ۰٫۰۰۸ از رشد و در C1/C3 انتخاب‌های پایانی از آن تأثیر گرفته‌اند	این بخش ممکن است در بخش private یا دادهٔ آینده تکرار نشود.
کاندیدهای آخر	C1 v83، C2 v123، C3 v129 در گزارش‌های نشست بی‌امتیاز مانده‌اند	هیچ‌کدام جای بهترین فایل تأییدشدهٔ این تحویل را نمی‌گیرند.

برای داوری، **قالب و هش چهار CSV** و **بازپخش cached نسخه‌های v42 و v120** در این تحویل کنترل شده‌اند؛ آموزش کامل از دادهٔ خام تا همهٔ خروجی‌های نهایی اثبات نشده است. هر امتیاز عمومی فقط به CSV مشخص در جدول بخش ۸ تعلق دارد. پذیرش سیگنال سؤال‌های دیگر و نتیجهٔ private با برگزارکننده است.